

Autostich — Balancing-Analyse (Detail)

Simulations-Report v2 · Runaway-Diagnose + konkrete Vorschläge

Formation-OFF (4 Blöcke) + Formation-ON (2 Blöcke) + Ice-fair-Nachlauf (Solver auch im Explore) · Mechaniken aus src/game verifiziert · Stand Autostich_Test

Detailanalyse mit optimierter Formations-Politik und vollständiger Stat-Bewertung. Der Score-Runaway hat ZWEI ungedeckelte Wurzeln, die sich verstärken. WICHTIGE KORREKTUR gegenüber der ersten Fassung: Eis & Blitz sind NICHT wertlos — ihre Legendaries sind stark; die frühere Aussage war ein Methodik-Artefakt (siehe Korrektur-Kasten unten). Jeder Vorschlag nennt Mechanik + konkrete Anpassung.

2 Treiber: SK_FIRE_08 + streakMult

Kern: ungedeckelte Serien-Skalierung

Eis/Blitz: nur Legendaries stark

Auf einen Blick

- **Treiber 1 — SK_FIRE_08 „Feuerwalze“:** jeder Sieg gibt der nächsten Karte +1 Wert (bis +5). win% 97–99 % in JEDEM Block (Formation OFF und ON). Baut die langen Siegesserien.
- **Treiber 2 — Stat „Serien-Multiplikator“ (streakMult):** +2 % Score je Serienpunkt je Pick, **UNGEDECKELT**. Mit optimierten Formationen wird er zum #2-Treiber (win% 93 %, in 100 % der Läufe). War ohne Formations-Optimierung unsichtbar.
- **Kernproblem:** Feuer baut die Serie, der Serien-Stat multipliziert mit der Serienlänge — beide ohne Deckel. Das ist der eine Kreislauf hinter der Runaway-Region (Score-Mediane 20–50 Mio).
- **Diversität (korrigiert):** Feuer ist breit stark (viele gute Skills). Eis & Blitz sind über ihre LEGENDARIES konkurrenzfähig (Permafrost 69 %, ein Blitz-Legendary 75 %) — aber ihre HÄUFIGEN Skills sind schwach. Das Diversitätsproblem sitzt also bei den Nicht-Legendary-Skills, nicht bei den Archetypen als Ganzes.
- **Sauber (kein Handlungsbedarf):** L2/L6 stark aber selten (Jackpots), die anderen Stats (Crit/Form/Einkommen) klein/neutral, solide Mittelfeld-Perks (C7/A10/B9/E4).
- **Empfehlung in einem Satz:** die Serien-Skalierung deckeln (streakMult wie der Basis-Faktor #100) und den Feuerwalzen-Snowball abflachen — das trifft den Runaway an der Wurzel. Blitz & Eis aufwerten. Keine Spielwerte wurden geändert.

Korrektur gegenüber der ersten Fassung (Eis & Blitz)

Die erste Fassung schrieb „Eis abwesend / unterpower“. Das war ein SIM-ARTEFAKT: Eis ist formationszentriert (eingefrorene Karten geben gratis Formations-Tausche + wirken als Joker), aber der Explore hatte die Aufstellung gar nicht optimiert — also sah er nie einen guten Eis-Build. Nach dem Fix (Formations-Solver auch im Explore + segmentübergreifende Frosttausche) tauchen Eis- UND Blitz-Skills in den Builds auf. Ergebnis: ihre LEGENDARIES sind stark (Permafrost 69 %, Frostbiss 67 %, ein Blitz-Legendary 75 %), ihre HÄUFIGEN Skills bleiben schwach. Die Diversitäts-Diagnose verschiebt sich damit von „ganze Archetypen schwach“ zu „nur die häufigen Nicht-Legendary-Skills schwach“.

1 · Der Runaway-Kreislauf (die Ursache)

Warum die Scores explodieren (der Kreislauf), Schritt für Schritt — jeder Pfeil ist ein Verstärkungsschritt:

- 1 SK_FIRE_08 + Hitze-Skills pumpen temporären KARTENWERT (Feuerwalze +1...+5, Glühende Klinge +2 ab 50 % Hitze).
- 2 Höherer Kartenwert → mehr gewonnene Stiche → längere SIEGESSERIE (die Feuerwalze wächst weiter, Verlust setzt sie zurück).
- 3 Der Stat „Serien-Multiplikator“ multipliziert den Score mit der Serienlänge: $\text{Faktor} = 1 + (\text{Picks} \times 2 \%) \times \text{Serie}$ — OHNE Deckel.
- 4 Höherer Score ändert das Kampfergebnis nicht direkt — aber die lange Serie hält Feuerwalze & Hitze oben, was Schritt 1 weiter befeuert.

Der Basis-Serien-Multiplikator (#39/#100) ist bereits bei +150 % gedeckelt (Serie 75). Die LÜCKE ist der Serien-STAT: er hat keinen Deckel, und mit optimierten Formationen (lange Serien) wird genau das zum zweiten Runaway-Ast.

2 · Methodik

Headless-Simulation direkt auf der puren Spiellogik (src/game/), seedbar und exakt reproduzierbar. UCB-Explore findet starke Builds und rankt Optionen; die gepaarte Ablation (gleicher Seed, mit vs. ohne eine Option) misst deren echten Beitrag.

Neu gegenüber dem ersten Report: (a) die Formations-Optimierung ist eingeschaltet (der Greedy-Solver ordnet Karten je Segment optimal an) — das war vorher aus Kostengründen aus; (b) alle fünf Stats werden jetzt IMMER ablatiert, nicht nur wenn sie zufällig oben ranken.

Leitmetrik ist win% — der Anteil Läufe (bedingt darauf, dass die Option im Spiel war), in denen der Build MIT der Option mehr Score erzielt als OHNE. Magnitude-immun und über Blöcke stabil. Da der Gegner ein gespiegeltes Deck ist, ist unser win% bereits ein reiner Build-vs-Build-Vergleich — nicht durch Mirror-Matches verzerrt (ein bekanntes Problem klassischer Winrates).

Score-Regime: Formation AUS vs. AN

Formations-Optimierung hebt das Score-Niveau massiv — ein Beleg, dass Formationen für starkes Spiel zentral sind (und dass der erste Report sie unterschätzt hat):

Modus	Blöcke	Full-Score Median	Formationsspiel
Formation OFF	4	1,6 – 31 Mio	naives Aufstellen (kein Umsortieren)
Formation ON	2	20 – 50 Mio	Segmente optimal angeordnet

3 · Daten


3.1 · Rangliste (mit Formations-Optimierung)

Cross-Block-Rangliste MIT Formations-Optimierung (2 Blöcke). Sortiert nach Entscheidungsrelevanz. win% = Richtung (hilft/schadet), typ. % = typische Score-Wirkung, im Spiel = wie oft die Option überhaupt gewählt wurde.

Option	Typ	win%	typ. Eff.	im Spiel	Tier · Urteil
SK_FIRE_08	skill	99%	+3973%	63%	S · Treiber #1
streakMult	stat	93%	+785%	100%	S · Treiber #2
L2	perk	89%	+229%	9%	A · Jackpot (selten)
SK_FIRE_06	skill	83%	+203%	60%	A · Feuer-Cluster
E4	perk	79%	+36%	51%	B · solide
B9	perk	79%	+38%	53%	B · solide
A10	perk	77%	+24%	48%	B · solide
C7	perk	75%	+23%	51%	B · solide
L6	perk	70%	+34%	11%	A · stark (selten)
critMult	stat	65%	+10%	1%	C · klein
critChance	stat	58%	-2%	2%	C · klein
formMult	stat	54%	+1%	2%	C · klein
A2	perk	54%	+1%	97%	C · Füller
A3	perk	48%	-3%	93%	C · Füller/Trap
SK_FIRE_12	skill	36%	-9%	3%	Trap (selten)
F-L1	shopitem	38%	+0%	2%	unzugänglich

Tiers: S = überstark (Nerf), A = stark/selten (ok), B = solide, C = Füller/klein, T = Trap/unzugänglich.

3.2 · win% der Top-Optionen



Gestrichelt: 50 %-Linie. Rechts = hilft, links = schadet. Lila = Stat, Orange = Feuer, Blau = Blitz.

3.3 · Archetyp-Diversität

Diversität ist ein zentrales Balance-Ziel (nicht EINE Option in fast jedem Build). Bild NACH dem Ice-fair-Fix — differenzierter als in der ersten Fassung:

Archetyp	Starke Skills in Builds	Befund
Feuer	SK_FIRE_08 (98 %), _06, _03, _10, _12	breit dominant — häufige UND legendäre Skills stark
Blitz	Legendary 75 %; häufige Skills ~50 %	über Legendary konkurrenzfähig, häufige Skills schwach
Eis	Permafrost 69 %, Frostbiss 67 %	Legendaries stark (selten), häufige schwach

3.4 · Eis/Blitz fair bewertet (Legendary vs. häufig)

Der Ice-fair-Nachlauf (Formations-Solver auch im Explore) macht Eis & Blitz erstmals sichtbar. Die Spaltung ist deutlich — Legendaries stark, häufige Skills schwach:

Skill	Kategorie	win%	im Spiel	Einordnung
SK_ICE_L02 (Permafrost)	Eis-Leg.	69%	5%	stark, selten
SK_LIGHTNING_L02	Blitz-Leg.	75%	1%	stark, sehr selten
SK_ICE_L01 (Frostbiss)	Eis-Leg.	67%	2%	positiv, selten
SK_LIGHTNING_02	Blitz	50%	39%	häufig, neutral
SK_ICE_03 (Eisschritt)	Eis	43%	54%	häufig, schwach
SK_ICE_02 (Kalte Präzision)	Eis	41%	39%	häufig, schwach

4 · Balancing-Vorschläge

Konkrete Vorschläge, nach Priorität. Jeder nennt die genaue Mechanik (Ist-Zustand), warum die Daten ein Problem zeigen, die vorgeschlagene Änderung und den erwarteten Effekt. NICHTS davon ist umgesetzt — das ist eine Entscheidungsvorlage.

NERF · WURZEL streakMult — Stat „Serien-Multiplikator“

Mechanik: Ist: +2 % Score pro aktuellem Serienpunkt je Pick (STAT_STREAK_MULT_STEP = 0,02), additiv, beliebig oft wählbar. Score-Faktor = $1 + (\text{Picks} \times 2\%) \times \text{Serie}$. UNGEDECKELT. Der Basis-Serien-Faktor (#39/#100) ist dagegen bei +150 % gedeckelt (ab Serie 75).

Problem: Mit optimierten Formationen werden Serien lang (40–200+). Bei 8 Picks (+16 %/Punkt) $\times$ Serie 40 = $\times 7,4$; $\times$ Serie 100 = $\times 17$; ohne Deckel weiter. In der Formation-ON-Analyse der zweitgrößte Treiber (win% 93 %, in 100 % der Läufe, typ. +785 %).

Vorschlag: Den Serien-Stat deckeln wie den Basis-Faktor: $\text{statStreakFactor} = 1 + \text{statStreakMult} \times \min(\text{Serie}, \text{CAP})$, z. B. CAP = 40–75. Alternativ Diminishing Returns pro Pick oder ein harter Gesamt-Cap (z. B. max +300 %).

Erwarteter Effekt: Kappt den zweiten Runaway-Ast, ohne den Stat bei normalen (kurzen) Serien zu verändern. Wichtigster Einzelfix.

NERF · QUELLE SK_FIRE_08 — „Feuerwalze“

Mechanik: Ist: jeder Sieg gibt der nächsten Karte +1 temporären Wert, steigend bis +5 (FIREROLL_MAX = 5); eine Niederlage setzt auf 0 zurück.

Problem: Wert-Snowball: verkettete Siege pumpen den Kartenwert → leichtere Siege → längere Serien → füttern den Serien-Stat (Treiber 2). In ALLEN Blöcken (OFF und ON) der #1-Beitrag, win% 97–99 %.

Vorschlag: FIREROLL_MAX 5→3 (flacherer Snowball) und/oder die Rampe verlangsamen (+1 je 2 Siege statt je Sieg). So bleibt der Skill stark, eskaliert aber nicht ins Uferlose.

Erwarteter Effekt: Bremsst den Serien-Aufbau an der Quelle. Zusammen mit dem streakMult-Deckel zähmt das den Kern-Runaway, ohne Feuer nutzlos zu machen.

BUFF · DIVERSITÄT Die HÄUFIGEN Eis- & Blitz-Skills aufwerten (Legendaries sind okay)

Mechanik: Ist (nach Ice-fair-Korrektur): die Legendaries tragen (Permafrost 69 %, Frostbiss 67 %, Blitz-Legendary 75 %), aber die häufigen Skills sind schwach/negativ — z. B. Eisschritt (SK_ICE_03) 43 %, Kalte Präzision (SK_ICE_02) 41 %, SK_LIGHTNING_02 ~50 %.

Problem: Ein Archetyp, der nur über seltene Legendaries funktioniert, ist unzuverlässig — man braucht Glück im Angebot. Die häufigen Skills bilden das Fundament und sind derzeit zu schwach, um ohne Legendary zu tragen.

Vorschlag: Die HÄUFIGEN Eis-/Blitz-Skills anheben (nicht die Legendaries), bis ein Eis-/Blitz-Build auch OHNE Legendary konkurrenzfähig ist. Konkrete Werte pro Skill über einen gezielten Sim-Vergleich (Ice-fair-Harness steht bereit).

Erwarteter Effekt: Eis/Blitz werden verlässlich baubar statt Legendary-abhängig — echte Build-Vielfalt statt Feuer-Monokultur.

REVIEW · TRAPS Trap-Optionen prüfen (negativer Beitrag)

Mechanik: E6 „Drehzahl“ (Karte darf zu zwei Treppen gehören), L8 „Schicksalsmaschine“ (bester/schlechtester Kartenwert tauschen je Durchlauf), D15 „Fehlzündung“ (jeder crit-lose Sieg lädt +30 Score für den nächsten Crit, max +300).

Problem: Ablation zeigt negativen Marginalbeitrag (win% < 45 %) — der Explorer nimmt sie (Korrelation), ihr Weglassen scoret aber öfter höher. Entweder Anti-Synergie/Bug oder schlicht zu schwach.

Vorschlag: Einzeln prüfen: Bug (unerwartete Anti-Synergie) fixen, sonst Zahlen anheben. Priorität niedrig — betrifft Rand-Optionen, nicht den Runaway.

Erwarteter Effekt: Weniger „Fallen“, in die ein guter Build hineinläuft; sauberere Entscheidungsräume.

Füller-Perks (A2/A3 „Gerade/Ungerade Stärke“)

Mechanik: Ist: A2 gibt allen Karten mit geradem Wert dauerhaft +1, A3 allen mit ungeradem. In 93–97 % der Läufe genommen, Beitrag ~null (win% ~48–54 %).

Problem: Fast immer genommen, aber ohne echte Entscheidung — reiner flacher Deck-Bonus. Verschenkter Entscheidungsraum (die Wahl fühlt sich nicht bedeutsam an).

Vorschlag: Optional: einen Trade-off/Bedingung geben (z. B. nur ein Segment, oder gekoppelt an eine Formation), damit die Wahl etwas bedeutet — oder bewusst als simple Grundstärke belassen.

Erwarteter Effekt: Interessantere frühe Entscheidungen; kein Balance-Notfall.

5 · Wie Studios & Analysten das angehen

Wie Studios und Analysten solche Fragen angehen — zur Einordnung der Methodik und der Empfehlungen:

Riot / Valorant — Data + Insights, Diversität als Ziel

Champion-/Agenten-Balance fußt auf presence (Pick-Rate) + winrate, aufgeschlüsselt nach Skill-Bracket. Ein erklärtes Ziel: dass man mit VIELEN Optionen erfolgreich sein kann — also aktiv gegen „eine Option in fast jedem Build“. Genau unser Diversitäts-Befund (Feuer-Monokultur). Wichtig für Mirror-Spiele: nicht die rohe, sondern die Nicht-Mirror-Winrate ansehen — unser win% ist bereits ein Build-vs-Build-Vergleich.

Slay the Spire — Winrate-getriebene Balance

Mega Crit veröffentlichte ~50 Mio. reale Runs; die Community balanciert über Karten-Winrate + Pick-Rate + Synergien. Unser win% ist dasselbe Signal, nur per Simulation VORAB erzeugt (bevor es Spielerdaten gibt).

Balatro — „brechen ≠ zerstören“

Multiplikativer Runaway ist dort Absicht (100-Mio-Scores by design). Die Grenze: der Spieler soll das Spiel BRECHEN (fühlt sich genial an), nicht ZERSTÖREN (trivialisiert alles ohne Aufwand). Unser Problem ist Letzteres: Feuer verdrängt die anderen Pfade.

Was Analysten in Reports sehen wollen

Nicht nur Punktwerte, sondern: Pick-Rate + Impact + Effektgröße + Konfidenz je Option, Verteilungen (Median/p90) statt nur Mittelwert, eine Diversitäts-/Tier-Sicht, und pro Empfehlung die Mechanik + konkrete Änderung + erwarteter Effekt. Genau diese Struktur nutzt dieser Report.

6 · Anhang

6.1 · Harness-Architektur

- Reine, deterministische Spiellogik (src/game/) → headless runOne(seed, policy); ein seedbarer PRNG pro Run.
- Explore: UCB1-Bandit über Stat/Perk/Skill/Shop, Archetyp-Kontext-Buckets, log1p-Reward. Eval: feste Prioritäts-Policy + gepaarte Ablation auf DISJUNKTEN Seeds.
- Robuste, tie-bewusste Marginals: win% (Vorzeichen-Test, bedingt auf „im Spiel“), median- Δ , typischer multiplikativer Effekt.
- Formations-Solver: greedy, intra-Segment (SEGMENT_SIZE = 5) — optimiert die Anordnung je Segment; Cross-Segment-Tausche bleiben außen vor (unterer Bound der Optimierung, dafür bezahlbar).
- Balance-Guard (Vitest) fängt versehentlichen Power-Creep bei künftigen Änderungen. Alle 410 Tests grün.

6.2 · Grenzen & Reproduzierbarkeit

- Die Policy spielt gut approximiert, nicht optimal → Richtungssignal, keine absolute Wahrheit.
- Gegner neutral (gespiegeltes Deck) → gemessen wird Build-Stärke, nicht Matchup-Dynamik.
- Absolute Beträge (typ.%, median- Δ) hängen vom Build-Regime ab (explosiv vs. mild); win% ist die über Läufe stabile Metrik.
- Formation-ON-Läufe waren kleiner (2 Blöcke, explore 4000) als Formation-OFF (4 Blöcke, explore 8000) — die Formations-ON-Beträge sind daher als Trend, nicht als exakte Größe zu lesen. Der Kernbefund (streakMult wird zum #2-Treiber) ist in beiden Blöcken robust.
- Ice-fair-Nachlauf: der Formations-Solver läuft jetzt auch im Explore (+ segmentübergreifende Frosttausche für eingefrorene Karten) — deshalb sind Eis & Blitz hier erstmals fair bewertet. Rest-Limitierung: die Kaltfront/Frostspur-Wertboni gehen nicht direkt in die Solver-Zielfunktion ein (der Ablations-Score misst sie aber, wenn Frosttausche fallen).
- Gemessen wurde die aktuelle Balance; die Spiellogik auf test/sim ist identisch zu Autostich_Test.

6.3 · Quellen

- playvalorant.com/en-us/news/dev/trust-the-balance-process-data-and-insights — Valorant: Data & Insights
- boostroyal.com/blog/How-Data-Drives-Champion-Balance — Riot Champion Balance (presence + winrate, Diversität)
- foxrow.com/slay-the-spire-statistical-analysis — Slay the Spire Winrate-Analyse (50 Mio Runs)
- ejaw.net/balatro — Balatro: brechen vs. zerstören
- ncbi.nlm.nih.gov/pmc/articles/PMC6319931 — Monte Carlo Automated Playtesting