

Autostich — Balancing-Analyse

Simulations-Report · headless UCB-Explore + gepaarte Ablation

4 unabhängige Seed-Blöcke · ~96 000 vollständige Runs · ~169 Mio. simulierte Stiche · Stand Autostich_Test
(Spiellogik identisch zu test/sim)

Diese Analyse spielt Autostich headless zehntausendfach durch und misst datengestützt, welche Optionen zu stark oder zu schwach sind — nicht nach Spielgefühl, sondern über Coverage-getriebene Exploration und gepaarte Ablation. Der Befund ist über alle vier Läufe hinweg außergewöhnlich konsistent.

SK_FIRE_08 = 97 % in 4/4 Blöcken

Feuer ist ein Cluster

Blitz & Eis unterpowert

Auf einen Blick

- **SK_FIRE_08** ist die mit Abstand dominanteste Option — win% 97 % in allen vier Blöcken, der größte Marginalbeitrag mit deutlichem Abstand. Klarer #1-Nerf-Kandidat.
- **Feuer** ist kein Einzel-Skill, sondern ein dominantes Archetyp-Cluster: auch SK_FIRE_06/_10/_12/_03 gewinnen 60–71 %. Ein Nerf nur an SK_FIRE_08 verschiebt die Macht innerhalb des Clusters.
- **Blitz und Eis** fehlen fast vollständig in starken Builds (nur ein einziger Blitz-Skill taucht auf, kein Eis) → deutlich unterpowert gegenüber Feuer.
- Eine explosive Runaway-Region (feuergetrieben) tritt in 2 von 4 Läufen auf: Full-Score-Median 25–31 Mio statt 1,6 Mio — die multiplikative Hitze-Skalierung.
- Nebenbefunde: Füller-Optionen (A2/A3: fast immer dabei, aber neutral), Trap-Optionen mit negativem Beitrag (E6, L8, D15, Zeitsegment A-L1), und unterzugängliche Shop-Legendaries (F-L1/K-L1/P-L1).
- **Keine Spielwerte wurden geändert. Dieser Report empfiehlt — die Balance-Entscheidung liegt bei dir.**

1 · Methodik — wie die Zahlen entstehen

Die Simulation nutzt direkt die reine Spiellogik (src/game/) — kein UI, kein Zufall außer einem seedbaren PRNG. Damit ist jeder Lauf exakt reproduzierbar (gleicher Seed → identisches Ergebnis) und tausende Runs laufen pro Minute headless in Node.

Zwei Phasen. EXPLORE: ein UCB-Banditen-Spieler wählt an jeder Entscheidung (Stat/Perk/Skill/Shop) adaptiv, bevorzugt aber noch ungesehene Optionen — so entsteht Coverage über den riesigen Optionsraum plus eine grobe Stärke-Rangliste. EVAL: eine feste Build-Policy wird auf frischen Seeds gegen sich selbst gespielt, aber mit je einer Option ENTFERNT (Ablation). Die gepaarte Differenz (gleicher Seed, mit vs. ohne) misst den echten Beitrag der Option — kausal, nicht bloß korreliert.

Leitmetrik ist win% — der Anteil Läufe (bedingt darauf, dass die Option überhaupt ins Spiel kam), in denen der volle Build besser abschneidet als ohne die Option. win% ist magnitude-immun und deshalb über Läufe hinweg vergleichbar, obwohl die Score-Verteilung extrem schwerschwänzig ist. Ergänzend: der typische multiplikative Effekt (typ.%) und wie oft eine Option überhaupt im Spiel ist (anwendbar%).

Diese Analyse fasst vier unabhängige Seed-Blöcke zusammen (je 8000 Explore- + 16 000 Eval-Läufe). Eine Option gilt als robust, wenn sie in mehreren Blöcken konsistent hoch (oder niedrig) abschneidet — der Cross-Block-Check trennt echtes Signal von Rauschen.

Warum das methodisch trägt (Einordnung aus der Forschung)

- Der Ansatz entspricht etablierter Praxis: automatisiertes Playtesting mit Monte-Carlo-Agenten wird in der Forschung genutzt, um Balance-Schwächen sichtbar zu machen und Wert-Konfigurationen zu optimieren.
- win% ist genau das Signal, mit dem Slay the Spire balanciert wird — Mega Crit hat ~50 Mio. reale Runs veröffentlicht, aus denen Karten-Winrates die Balance treiben. Wir erzeugen dasselbe Signal in-house per Simulation, bevor es echte Spielerdaten gibt.
- Die Ablation ist das kausale Upgrade gegenüber roher Winrate-Korrelation: sie beantwortet „was trägt diese Option WIRKLICH bei“, nicht „welche Builds scoren zufällig hoch“.

2 · Daten

2.1 · Die vier Läufe (Seed-Blöcke)

Vier Läufe mit disjunkten Seeds. Auffällig: dieselbe Konfiguration erzeugt je nach Explore-Pfad zwei Regime — milde Builds (~1,6 Mio Median) oder eine explosive, feuergetriebene Runaway-Region (25–31 Mio).

Beide sind real erreichbar; welches Regime ein Lauf findet, hängt am Seed.

Block	Seeds	Explore	Eval	Full-Score Median	Regime
A	1 – 9 000	8 000	1 000	1,639,050	mild
B	250 000 – ...	8 000	1 000	24,585,970	explosiv
C	500 000 – ...	8 000	1 000	31,432,857	explosiv
D	750 000 – ...	8 000	1 000	1,714,542	mild

„Regime“ = ob der Lauf die explosive Feuer-Runaway-Region gefunden hat. 2 von 4 Läufen taten es — die Region ist kein Ausreißer, sondern ein reproduzierbarer Zustand.


2.2 · Cross-Block-Rangliste (robuste Metriken)

Cross-Block-Aggregat je Option: in wie vielen der 4 Blöcke sie ablatiert wurde, die mittlere win% (bedingt auf „im Spiel“), der typische Effekt, wie oft sie im Spiel war, und der Median der Median-Δ. Sortiert nach Entscheidungsrelevanz (Feuer-Cluster gruppiert).

Option	Typ	#Bl.	win%	typ. Eff.	im Spiel	Median-Δ	Urteil
SK_FIRE_08	skill	4	97%	+1776%	64%	28,981,710	dominant · #1
SK_FIRE_06	skill	3	71%	+40%	59%	439,340	Feuer-Cluster
SK_FIRE_12	skill	1	67%	+100%	6%	22,186,510	Feuer-Cluster
SK_FIRE_10	skill	1	61%	+66%	63%	7,316,696	Feuer-Cluster
SK_FIRE_03	skill	1	64%	+33%	47%	3,749,833	Feuer-Cluster
L2	perk	4	86%	+142%	13%	24,015,587	Jackpot · selten
L6	perk	4	76%	+52%	13%	4,001,159	stark · selten
C7	perk	4	68%	+17%	51%	923,112	solide
A10	perk	4	67%	+12%	51%	683,682	solide
A8	perk	4	59%	+6%	51%	244,493	mild
B9	perk	2	65%	+7%	53%	376,214	mild
SK_LIGHTNING_07	skill	1	66%	+5%	63%	54,820	einziger Blitz
A2	perk	2	50%	-0%	98%	3,910	Füller · neutral
A3	perk	1	54%	+6%	95%	229,290	Füller · neutral
F-L1	shopitem	4	57%	+1%	7%	71,478	Legendary · selten
A-L1	shopitem	3	30%	-2%	9%	-54,560	Trap · Zeitseg.
E6	perk	1	38%	-3%	57%	-36,215	Trap · schadet
L8	perk	1	38%	-2%	9%	-594,847	Trap · schadet
D15	perk	1	37%	-3%	45%	-169,452	Trap · schadet

win% = Anteil Läufe (bedingt auf „Option im Spiel“), in denen der volle Build besser abschneidet als ohne die Option. Magnitude-immun → über Blöcke vergleichbar. Typischer Effekt und Median-Δ hängen dagegen vom Build-Regime ab.

2.3 · win% der Top-Optionen (über alle Blöcke gemittelt)



Gestrichelt: 50 %-Linie (Option irrelevant). Rechts davon = hilft, links = schadet.

3 · Rückschlüsse

3.1 · Feuer ist kein Einzel-Skill, sondern ein dominantes Archetyp-Cluster

SK_FIRE_08 gewinnt in allen vier Blöcken 93–99 % (Aggregat 97 %) und ist überall der größte Beitrag mit klarem Abstand. Das allein wäre schon ein eindeutiger Nerf-Kandidat.

Entscheidend aber: Feuer hat eine tiefe Bank. SK_FIRE_06 (71 %, 3 Blöcke), SK_FIRE_12 (67 %), SK_FIRE_10 (61 %), SK_FIRE_03 (64 %) sind alle überdurchschnittlich stark. Block C exploriert sogar einen fast reinen Feuer-Build (vier Feuer-Skills in den Top). Würde man nur SK_FIRE_08 abschwächen, flösse die Macht schlicht zum nächsten Feuer-Skill.

3.2 · Die explosive Runaway-Region ist real und feuergetrieben

In 2 der 4 Läufe (B, C) läuft der Score in eine explosive Region: Full-Score-Median 25–31 Mio statt 1,6 Mio in den milden Läufen (A, D). Das ist die multiplikative Hitze-Skalierung, die alles mitzieht.

Genau hier zählt sich die robuste Metrik aus: die absoluten Beträge (typ.%, Median-Δ) explodieren in diesen Blöcken mit — aber win% bleibt stabil bei 97–99 % für SK_FIRE_08. Die Richtung ist felsenfest, die Höhe hängt am Regime.

3.3 · Blitz und Eis sind unterrepräsentiert → unterpower

In den starken Builds über alle vier Blöcke taucht genau EIN Blitz-Skill auf (SK_LIGHTNING_07, 66 %, mild) und KEIN einziger Eis-Skill. Der Explorer baut sie kaum, weil Feuer dominiert und sie im direkten Vergleich verlieren.

Das ist die Kehrseite des Feuer-Problems: es geht nicht nur darum, dass Feuer zu stark ist, sondern dass zwei von drei Archetypen praktisch nicht konkurrenzfähig sind.

3.4 · Füller-Optionen und Trap-Optionen

- **Füller (neutral trotz Allgegenwart):** A2 ist in 98 % der Läufe im Build, A3 in 95 % — aber beide tragen ~null bei (win% ~50–54 %). Sie werden immer genommen und ändern nichts.
- **Traps (negativer Beitrag):** E6 (38 %), L8 (38 %), D15 (37 %) und das Zeitsegment A-L1 (30 %) schneiden schlechter ab als ihr Weglassen. Der Explorer nimmt sie (Korrelation), die Ablation entlarvt sie — entweder Anti-Synergie/Bug oder schlicht schwach.

3.5 · Legendaries — stark & selten (okay) vs. unterzugänglich

L2 (86 %) und L6 (76 %) sind stark, aber nur in ~13 % der Läufe überhaupt angeboten. „Selten + stark“ ist ein gesundes Jackpot-Design, kein Balance-Problem.

Shop-Legendaries (F-L1, K-L1, P-L1) dagegen sind in ~0–8 % der Läufe erreichbar — sie werden fast nie gekauft (zu teuer / zu selten im Angebot). Falls sie build-definierend gedacht sind, sind sie derzeit praktisch unerreichbar.

4 · Empfehlungen

Die Kernfrage (frei nach der Roguelite-Design-Debatte): „bricht“ Feuer das Spiel auf befriedigende, optionale Weise — oder „zerstört“ es die anderen Pfade? Die Daten sagen: eher zerstören. Feuer dominiert UND Blitz/Eis sind abwesend. Das spricht für einen Eingriff — mit folgenden Hebeln, in dieser Reihenfolge:

1. An der Wurzel nerfen, nicht am Einzel-Skill

Weil Feuer ein Cluster ist, setzt der wirksamste Eingriff an der GEMEINSAMEN Mechanik an — der Hitze-Skalierung (Hitzegewinn pro Vorsprung, Skalierungsdeckel, Konsumenten-Auszahlung) — statt nur SK_FIRE_08 zu schwächen.

Das ist zugleich der elegante Weg: eine Wurzel-Änderung statt vieler Einzel-Nerfs (die Community-Faustregel „lieber eine Sache nerfen als zehn buffen“ gilt hier für das Feuer-Cluster).

2. Blitz & Eis aufwerten — nicht nur Feuer senken

Der gesündere Hebel in einem PvE-Roguelite ist oft, die schwachen Optionen zu heben statt nur die starke zu senken. Blitz und Eis brauchen genug Kraft, um in die Explore-Builds zu kommen; erst dann diversifizieren sich die Builds.

Zielbild: In einem künftigen Sim-Lauf sollten Blitz- und Eis-Skills überhaupt in den Top-Ranglisten auftauchen — heute tun sie es praktisch nicht.

3. Füller-Perks interessanter machen (A2, A3)

Optionen, die fast immer genommen werden, aber nichts entscheiden, sind verschenkter Entscheidungsraum. Entweder bekommen sie einen echten Trade-off/Nutzen, oder sie sind faktisch tote Picks.

4. Trap-Optionen prüfen (E6, L8, D15, Zeitsegment A-L1)

Negativer Marginalbeitrag heißt: aktiv schädlich. Das ist entweder ein Anti-Synergie-Bug oder ein echt schwaches Design. Besonders das Zeitsegment-Shop-Item (A-L1) verdient einen Blick — es schadet im Schnitt.

5. Shop-Legendaries zugänglicher machen (falls beabsichtigt)

Wenn F-L1/K-L1/P-L1 build-definierend sein sollen, sind sie mit ~0–8 % Erreichbarkeit zu selten. Preis/Angebotshäufigkeit anpassen — oder bewusst als extreme Seltenheit belassen.

6. Alternative: den Runaway bewusst zulassen — aber gaten

Falls die explosive Feuer-Region als „Power-Fantasy“ gewollt ist (Balatro macht das bewusst): behalten, aber hinter mehr Aufbau/Voraussetzungen stellen, damit sie nicht das Grundspiel trivialisiert — und Blitz/Eis trotzdem aufwerten. „Brechen“ ist okay, „zerstören“ nicht.

Jede dieser Änderungen berühre ich erst nach deiner ausdrücklichen Freigabe. Der Report gibt Richtung — die Entscheidung bleibt bei dir.

5 · Wie vergleichbare Spiele das angehen

Zur Einordnung, wie vergleichbare Spiele mit multiplikativer Skalierung und Synergie-Ökonomien umgehen:

Balatro — Runaway ist Absicht, „brechen ≠ zerstören“

Balatro ist auf dem Papier komplett unbalanciert — Spieler erreichen regelmäßig 100-Mio-Scores über xMult-Joker-Synergien, die multiplikativ eskalieren. Der Entwickler lässt das bewusst zu.

Die Design-Grenze ist „das Spiel BRECHEN“ (der Spieler findet eine mächtige Combo und fühlt sich genial) vs. „es ZERSTÖREN“ (jede Herausforderung wird mühelos trivial). Lehre für uns: Feuers Runaway ist nicht automatisch schlecht — problematisch ist, dass es die anderen Archetypen verdrängt (zerstören, nicht brechen).

Slay the Spire — datengetriebene Balance über Winrates

Mega Crit stellte ~50 Mio. reale Runs (40 GB) zur Verfügung; die Community-Analytik (Heart Rate, STS-Tracker) trackt pro Karte Winrate + Pick-Rate + Synergien. Balance-Entscheidungen fußen auf diesen Winrates.

Unsere win%-Metrik ist genau dieses Signal — nur erzeugen wir es per Simulation im Voraus, statt auf Millionen echter Runs zu warten.

Luck be a Landlord — Solo-Dev, iterative Synergie-Balance

Ein Solo-Entwickler (wie hier), dessen Symbol-Synergie-Ökonomie unserer Archetyp-Synergie ähnelt. Balance lief über iterative Patches inklusive Entfernen/Reworken überstarker Symbole. Lehre: kontinuierliches, datengestütztes Nachjustieren einer Synergie-Ökonomie statt eines großen Wurfs.

Forschung — automatisiertes Playtesting

Monte-Carlo-Agenten als Proxy für rationale Spieler decken Imbalancen in Wert-Konfigurationen auf; evolutionäre und Ablations-Methoden finden und optimieren sie. Unser UCB-Explore + Ablation ist eine leichtgewichtige, deterministische Variante genau dieser Idee.

6 · Anhang

6.1 · Harness-Architektur

- Reine, deterministische Spiellogik (src/game/) → headless runOne(seed, policy); ein seedbarer PRNG pro Run.
- Explore: UCB1-Bandit über Stat/Perk/Skill/Shop-Optionen, Archetyp-Kontext-Buckets, log1p-normalisierter Reward.
- Eval: feste Prioritäts-Policy + gepaarte Ablation auf DISJUNKTEN Seeds (Explore- und Eval-Seeds getrennt → kein Feedback-Bias).
- Robuste Marginals: median- Δ , win% als tie-bewusster Vorzeichen-Test (bedingt auf „im Spiel“), typischer multiplikativer Effekt.
- Balance-Guard (Vitest): Random-Policy über feste Seeds, Median+Mean im Band → fängt versehentlichen Power-Creep bei künftigen Änderungen.

6.2 · Grenzen & Reproduzierbarkeit

- Die Policy spielt gut approximiert, nicht optimal → Richtungssignal, keine absolute Wahrheit.
- Der Gegner ist neutral (gespiegelter Deck, keine KI) → gemessen wird die Build-Stärke, nicht Matchup-Dynamik.
- Absolute Beträge (typ.%, Median- Δ) hängen vom Build-Regime ab (explosiv vs. mild); win% ist die über Läufe stabile Metrik.
- Formations-Solver war in diesen Läufen aus (Kostengründe); Shop-Items werden gekauft, Shop-Legendaries aber selten erreicht.
- Gemessen wurde die aktuelle Balance — die Spiellogik auf test/sim ist identisch zu Autostich_Test (die jüngsten Commits dort sind reine UI-Änderungen).

6.3 · Quellen (Recherche)

- ejaw.net/balatro — „Why Balatro's Low-Key Difficulty Is a Masterclass in Game Design“
- balatrowiki.org/w/Guide:_Scaling — multiplikative Skalierung
- foxrow.com/slay-the-spire-statistical-analysis — StS-Winrate-Analyse (50 Mio Runs)
- sts1.heart-rate.net — Slay the Spire Statistik
- en.wikipedia.org/wiki/Luck_Be_a_Landlord — Solo-Dev, Balance-Patches
- ncbi.nlm.nih.gov/pmc/articles/PMC6319931 — A Monte Carlo Approach to Skill-Based Automated Playtesting
- arxiv.org/pdf/2006.04419 — Metagame Autobalancing for Competitive Multiplayer Games